

贺融

新加坡 | hanserong@u.nus.edu | rong.bio

教育背景

新加坡国立大学 软件工程技术硕士	2026.08 – 2027.10
韩国科学技术院 (KAIST) 计算机科学学士 GPA 86/100, 专业前 5%	2021.09 – 2025.08

实习经历

上汽集团 AI 智能体开发工程师	2026.02 – 2026.07 上海
- 四个智能体落地：对接内部工程、产品规划与项目管理三个部门的降本增效需求，独立交付连接器选型、竞品分析、PRD 生成审核、黑盒智能体测试四个智能体，累计服务约 500 名内部用户。 - 连接器选型智能体：Flask + LangChain + MongoDB, 8.5k 行 Python。用 LLM 做意图识别，把一句自然语言拆成精确匹配、模糊匹配、范围查询三类条件，并行检索五个产品集合并自动完成字段名映射。工程师确认过的结果回写知识库，同类问题直接复用历史模板，形成人工确认闭环。前后迭代八个版本，其中一次完成数据集整体迁移与 fallback 链路简化。 - 竞品分析智能体：以 LLM 驱动的爬虫采集竞品车型的公开用户评论并入库 MongoDB，再由六个章节级智能体串成报告流水线，自动生成有数据支撑的结构化竞品分析报告。 - AUT 黑盒智能体测试工具：自研，3.1k 行 Python。Playwright 自动完成登录（验证码、SSO、MFA 等场景支持人工接管）、定位对话入口、抓取真实 API 调用并生成可重放的请求模板；再按成功率、错误率、p95 设置自动熔断条件做分级并发压测，内置提示词注入、跨会话信息泄露、输出格式稳定性三类探针。用它实测出连接器智能体的性能拐点：20 并发下成功率 100%、p95 14.2 秒；压到 500 并发时成功率降至 94.9%，1000 次请求中有 51 次返回空值或不合规内容。	
郑州捷安高科 算法工程师	2025.09 – 2026.01 郑州
- 特种作业智能考评系统：与市应急管理局合作的项目，负责其中的视觉算法。现场以四到五路摄像头同步采集，由模型判定考生操作的合规性与流程完整性，替代人工监考打分。系统连续一个多月、每个工作日承担正式考试，本人负责其中三条产线，并与数据部门共同制定标注规范，保证标注口径与算法假设一致。 - 图结构建模替代规则判定：原方案是 YOLO 检测加人工规则，因忽略部件之间的空间关系而判定不准。改为由 YOLOv8 输出部件的中心点、尺寸、角度与类别，按各搭设步骤的约束关系组织成图，再用图卷积网络预测部件安装状态与步骤完成状态。模型内部验收准确率约 90%；另设人工陪考加平板打分的降级通道，保证算法异常时考试不中断。	
上海亚太神通计算机 软件开发工程师	2023.07 – 2023.08 上海
企业 Java Web 系统：承担业务功能开发与日常维护，并完成配套前端页面及一个微信小程序。针对高峰并发对数据库访问层做调优：重估连接池容量、将逐条读写改为批量操作、简化查询语句，此后高峰时段的连接等待告警不再出现。这段经历真正留下的是排查方法——先定位等待发生在哪一环，再决定调哪个参数。	
项目经历	
coding-agent-from-scratch —— 终端编程智能体 开源个人项目	2026.09 – 至今 github.com/Darrenus/coding-agent-from-scratch
- 整体设计：不依赖任何智能体框架、从零实现的命令行编程助手：基于原生工具调用的 ReAct 主循环、七个工具，以及由四级匹配策略链支撑的 SEARCH/REPLACE 增量编辑——用以吸收模型复述代码时产生的行尾空白与半行截断偏差。shell 执行由 macOS Seatbelt 策略约束，其有效性靠逃逸测试验证而非阅读策略文本。核心代码约 1,300 行，52 个测试，其中九个专门尝试突破沙箱。 - 仓库地图：决定哪部分代码进入上下文：tree-sitter 抽取符号的定义与引用，按引用关系把文件连成有向图，再以个性化 PageRank 针对当前任务排序。用真实的 Python 导入关系约束边，使边的精确率从 32% 提升到 100% 且未丢失任何真边；真正的瓶颈是查询理解而非排序算法，由 IDF 加权的种子提取解决。在 112 个文件的仓库上，该地图使任务步数下降 21%、输入 token 下降 33%。 - 可测量，包括负面结论：每个设计决策都由对照实验裁决，评测框架默认附带 A/A 对照组，使每个效应都与自身的噪声底噪并列呈现——这套纪律撤回了我此前的一个结论。两个教科书级的智能体模式在该架构下被实测为净亏损：工具输出一旦封顶，历史压缩便无必要；子智能体隔离多消耗 42% 的总 token，仅换来主循环上下文减少 22%，而完成率与正确率均无改善。原始轨迹全部提交，所有数字可被重新推导。	
bodycraft-oss —— 多路检索引擎 开源个人项目	2026.04 – 2026.07 上海
五路并行召回：文件名与路径、章节标题、SQLite FTS5 分词全文检索、稠密向量、实体图谱五条路径并行运行，由四套相互独立的权重策略分别打分后按文件归并，并把每条路径的得分明细一并返回，而不是藏在调试开关后面。	

- 权重靠搜索确定，不靠手感：把评分公式中所有硬编码参数提取为可热加载配置；相关性标签取自 模型实际展开了哪些文件，属弱监督，并记录标签来源以免与人工标注混淆；优化目标选 NDCG，因为比值型指标可以靠把权重压到单一路径刷高，而排序质量实际在下降。先用网格搜索粗定范围，再用 遗传算法独立跑多轮，以轮次之间的离散程度区分真实提升与噪声。索引结构、配置格式与排序指标已在 17 个测试下建成，全流程无需 API key 即可离线运行。

内部表格问答平台 —— 对话式表格分析平台

2026.02 – 2026.04

负责人 · 上汽内部项目

上海

- 平台概况：把用户对上传表格提出的自然语言问题，转化为经校验的 SQL、结果表与图表。后端 FastAPI + SQLAlchemy，76 个模块、23,331 行代码、56 个测试文件，依赖 MySQL、Redis、MinIO 与 通义千问；前端 7,487 行 React 19，经 SSE 流式返回。上线 20 余名内部试用用户，据其反馈估算 人均每天减少约 2 小时手工表格工作。
- Planner – Executor 重构：把原本固定的 LLM 工作流改成两层：规划器只输出结构化计划（意图、目标字段、动作序列、约束、失败策略），执行器只执行白名单动作，运行在带表级、字段级、权限级 白名单的只读 SQL 层之上，数据以组织和角色为边界隔离。会话上下文、已生成的 SQL 与图表配置均 持久化，使追问能够承接此前轮次。
- 专利与二次架构：合著该设计的专利技术交底书（2026.06 申请，审查中），其中定义了执行前的 门控指标 $S = 0.35F + 0.25A + 0.20C + 0.10P + 0.10R$ ，访问合规度 A 为硬性门槛。随后把核心 能力重写为开源智能体运行时的原生工具，模型仅能看到受控的 `clarify / result_table / result_chart` 三个协议。

研究成果

arXiv

Rong He. Decomposition Buys Integrity, Not Yield. [arXiv:2609.17464](#) [cs.MA], 2026.09

多智能体系统把任务拆到子智能体树上时，分解提升了 integrity——单个智能体面对的上下文更小——却牺牲了 yield，即叶节点发现的信息能回传到根节点的比例。文中把留存概率建模为 $r(b) = 1/b$ ，在 20,000 棵不规则树上验证，并从 600 条生产环境 deep-research 轨迹中还还原出指数 0.34，说明任务规模与架构是两个可分离的变量。对 743,819 次生产工具调用的分析显示，仅 0.7% – 11.3% 的会话真正值得委派，而实际委派率为 7.8%：单看 yield，扁平结构最优；分解的价值 应落在控制根节点上下文与成本上。

Rong He. Prefix Sharing Is a Sorting Problem. [arXiv:2609.13692](#) [cs.DS], 2026.09, 15 页

LLM 服务按精确前缀匹配复用 KV cache，因此当 prompt 由检索段落、工具定义、few-shot 样例等 可复用片段拼装而成时，片段的排列顺序直接决定了可共享的计算量。现有系统一律采用固定的全局 顺序，文中证明该做法仅在每个请求至多包含两个片段时最优。片段排序等价于在请求集合上选取一棵 二叉层次树，leave-one-out 情形的最优解即归并排序递归，固定全局顺序须付出 $\Theta(n^2)$ ，而真实代价仅 $\Theta(n \log n)$ 。在三个 BEIR 语料的 BM25 检索轨迹上，该布局相比生产环境的 RAG 排序减少 17% – 36% 的 prefill 计算。

Rong He. Sharp Limits on Time-Reversal Detection in Binary Hidden Markov Models. Zenodo, 2026. DOI: [10.5281/zenodo.22684760](#)

构造转移与发射均严格为正的平稳二元隐马尔可夫模型，使其观测在任意 $2n - 4$ 个采样时刻上都无法 分辨时间方向，并证明与之匹配的检测尺度 $\Theta(|\theta|^{-(4n-6)})$ 是紧的。

专利

一种面向电子表格自然语言问答的可审计规划执行方法及系统 | 第二发明人，已提交受理暂未公开

专业技能

编程语言	Python、TypeScript、Java、C++、SQL、Go
智能体	Planner-Executor 架构、工具调用与 function calling、记忆与上下文工程、多智能体编排、MCP、LangGraph
RAG	全文、稠密向量与实体图谱的混合检索；查询理解、分数融合、上下文装配、KV-cache 前缀复用
评测	评测集构建与排序指标、消融实验与参数搜索、并发压测与对抗性测试
分布式	Python 后端服务、异步任务流水线与消息队列、SSE 流式传输、基于角色的数据隔离、CI
数据	MySQL、MongoDB、Redis、SQLite、MinIO、Chroma；表结构画像与数据接入流水线
视觉	目标检测与姿态估计、图神经网络、GPU 推理部署
语言	英语（TOEFL 90）、韩语（TOPIK 二级）

荣誉奖项

牛客 AI Coding 挑战杯决赛 Top 10（2026） | 首届“国机杯”工业智能体大赛优秀奖（2026） | 美国大学生数学建模竞赛（MCM）Honorable Mention（2024）